

Transformació & Selecció

Wenjia Ye

2025-10-11

Transformació

S'ha decidit transformar les variables ComplaintsCount i NumOfProducts en variables categòriques, ja que en ambdós casos presenten una distribució molt desequilibrada.

En el cas de ComplaintsCount, la gran majoria de clients no han presentat cap queixa, mentre que només una petita proporció n'ha fet una o més. Per tant, es transforma en una variable binària amb dos nivells:

- 0: el client no s'ha queixat
- 1: el client sí que s'ha queixat

De manera similar, la variable NumOfProducts mostra que la major part dels clients tenen un sol producte, uns quants en tenen dos, i només una minoria en té tres o més. Per això, s'ha recodificat en tres categories:

- Clients amb 1 producte
- Clients amb 2 productes
- Clients amb 3 o més productes

En tots dos casos, la transformació de variables numèriques a categòriques permet reduir la influència de valors poc freqüents, evitar soroll estadístic i facilitar la interpretació dels resultats. A més, aquesta simplificació pot contribuir a millorar l'estabilitat i rendiment dels models predictius, especialment en aquells que treballen millor amb variables discretes o amb distribucions equilibrades.

```
load("C:/Users/34688/OneDrive - Universitat de Barcelona/Escritorio/Mineria/DATA/data_imputado.RData")
data<-data_imputado
data$ComplaintsCount_bin <- ifelse(data$ComplaintsCount == 0, 0, 1)
data$ComplaintsCount_bin <- factor(data$ComplaintsCount_bin,
                                      levels = c(0, 1),
                                      labels = c("No_queja", "Queja"))

data$NumOfProducts_grupo <- ifelse(data$NumOfProducts == 1, "1",
                                      ifelse(data$NumOfProducts == 2, "2", "3 o más"))
data$NumOfProducts_grupo <- factor(data$NumOfProducts_grupo,
                                      levels = c("1", "2", "3 o más"))
```

Selecció

Un cop imputades i analitzades les dades, tal com s'ha mencionat anteriorment, es decideix reduir el dataset centrant-se en les variables que presenten una forta relació amb la variable resposta. Tot i que anteriorment ja s'havien realitzat proves per identificar quines variables eren estadísticament significatives, les transformacions i imputacions recents poden haver modificat les distribucions i relacions originals, tot i que no ha de passar.

Per aquest motiu, es tornen a aplicar els tests estadístics corresponents:

- Test de mediana per a les variables numèriques
- Test de Chi-quadrat per a les variables categòriques

Aquesta nova evaluació garanteix que la selecció de variables sigui coherent amb el dataset final, després de totes les modificacions realitzades.

```
varCat<-c("Geography", "Gender", "MaritalStatus", "EducationLevel", "HasCrCard",
         "SavingsAccountFlag", "LoanStatus", "CustomerSegment", "Exited", "IsActiveMember", "ComplaintsCo
varNum<-c("Age", "CreditScore", "Tenure", "EstimatedSalary", "Balance", "TransactionFrequency", "AvgTransa
v<-"Exited"
for (varc1 in varCat) {
  if (varc1 != v) {
    tab <- table(data[[v]], data[[varc1]]) # filas = Exited, columnas = categorías
    test <- chisq.test(tab, correct = FALSE)

    cat("\nVariable:", varc1, "\n")
    cat("Chi-squared =", round(test$statistic, 3),
        "df =", test$parameter,
        "p-value =", signif(test$p.value, 5), "\n")

    if (test$p.value < 0.05) cat("-> Diferencias significativas entre columnas\n")
  }
}

## 
## Variable: Geography
## Chi-squared = 97.683 df = 2 p-value = 6.1421e-22
## -> Diferencias significativas entre columnas
##
## Variable: Gender
## Chi-squared = 55.63 df = 1 p-value = 8.746e-14
## -> Diferencias significativas entre columnas
##
## Variable: MaritalStatus
## Chi-squared = 1.883 df = 3 p-value = 0.59695
##
## Variable: EducationLevel
## Chi-squared = 3.899 df = 3 p-value = 0.27254
##
## Variable: HasCrCard
## Chi-squared = 0.425 df = 1 p-value = 0.5143
##
## Variable: SavingsAccountFlag
## Chi-squared = 0.404 df = 1 p-value = 0.52506
##
## Variable: LoanStatus
## Chi-squared = 0.218 df = 2 p-value = 0.89689
##
## Variable: CustomerSegment
## Chi-squared = 1.199 df = 2 p-value = 0.54901
##
## Variable: IsActiveMember
## Chi-squared = 74.063 df = 1 p-value = 7.5648e-18
```

```

## -> Diferencias significativas entre columnas
##
## Variable: ComplaintsCount_bin
## Chi-squared = 0.006 df = 1 p-value = 0.93943
##
## Variable: NumOfProducts_grupo
## Chi-squared = 541.239 df = 2 p-value = 2.961e-118
## -> Diferencias significativas entre columnas

resultados_mediana <- data.frame(
  Variable = character(),
  Mediana_Exited0 = numeric(),
  Mediana_Exited1 = numeric(),
  p_value = numeric(),
  stringsAsFactors = FALSE
)

for (var in varNum) {
  medianas <- tapply(data[[var]], data$Exited, median, na.rm = TRUE)
  p_val <- wilcox.test(data[[var]] ~ data$Exited)$p.value

  resultados_mediana <- rbind(resultados_mediana, data.frame(
    Variable = var,
    Mediana_Exited0 = medianas["0"],
    Mediana_Exited1 = medianas["1"],
    p_value = p_val
  ))
}
resultados_mediana

##           Variable Mediana_Exited0 Mediana_Exited1      p_value
## 0              Age     36.00000     43.00000 5.036801e-82
## 01             CreditScore   652.00000    647.00000 1.239849e-01
## 02            Tenure      5.00000      5.00000 8.658442e-01
## 03       EstimatedSalary   98857.51500   103537.00500 1.401894e-01
## 04            Balance    94243.22000   107850.82000 2.264889e-13
## 05 TransactionFrequency     30.00000     30.00000 7.811747e-01
## 06 AvgTransactionAmount    99.32957     97.59089 6.395712e-01
## 07 DigitalEngagementScore   60.00000     60.00000 3.507634e-01
## 08 NetPromoterScore        8.00000      8.00000 7.625010e-01

```

Un cop efectuats els tests estadístics pertinents, s'ha constatat un canvi en relació amb els resultats obtinguts abans de la imputació. Les variables CreditScore i EstimateSalary han deixat de ser estadísticament significatives. Aquest resultat no és inesperat, ja que anteriorment presentaven p-valors només lleugerament inferiors a 0,05, fet que ja indicava una significació marginal.

```
data_transformada <- subset(data, select = -c(ComplaintsCount, NumOfProducts))
```

```
data_reducida<-data[,c("Geography", "Gender", "Exited", "IsActiveMember", "NumOfProducts_grupo", "Age", "Ba
```